Ενότητα 07: Ιεραρχία Μνήμης Ι

ΕΕΙ 233: ΟΡΓΑΝΩΣΗ ΥΠΟΛΟΓΙΣΤΩΝ

ΑΝΔΡΕΑΣ ΔΙΑΒΑΣΤΟΣ

andreas.diavastos@cut.ac.cy

Τεχνολογικό Πανεπιστήμιο Κύπρου | Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής

CARL

1

Τεχνολογικό Πανεπιστήμιο Κύπρου | Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής

Outline

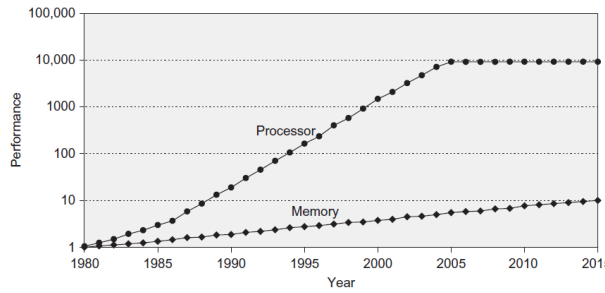
- Ιεραρχία της Μνήμης
- Cache
- Main Memory (DRAM)
- Virtual Memory

- Υλικό από Κεφάλαιο 7 του βιβλίου του μαθήματος

2

Εισαγωγή

- Ιδανικά για τη μνήμη σαν προγραμματιστές θα θέλαμε:
  - Άπειρο μέγεθος
  - Άπειρη Ταχύτητα
  - Κοντά στον επεξεργαστή για γρήγορη πρόσβαση



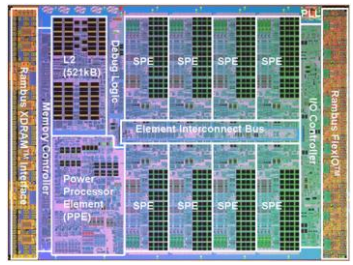
Memory Technologies

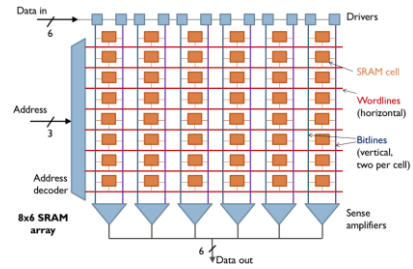
	Capacity	Latency	Cost/GB	
Register	1000s of bits	20 ps	$$$$	Processor Datapath
SRAM	~10 KB-10 MB	1-10 ns	~$1000	Memory Hierarchy
DRAM	~10 GB	80 ns	~$10	
Flash*	~100 GB	100 us	~$1	I/O subsystem
Hard disk*	~1 TB	10 ms	~$0.10	

* non-volatile (retains contents when powered off)

Static Random Access Memory (SRAM)

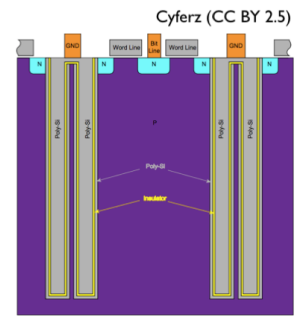
- Designed for low Access Latency
- Χρησιμοποιείται για την κατασκευή Caches
- Χαμηλή ενέργεια για διατήρηση των δεδομένων
- Χρειάζεται 6 transistors/bit





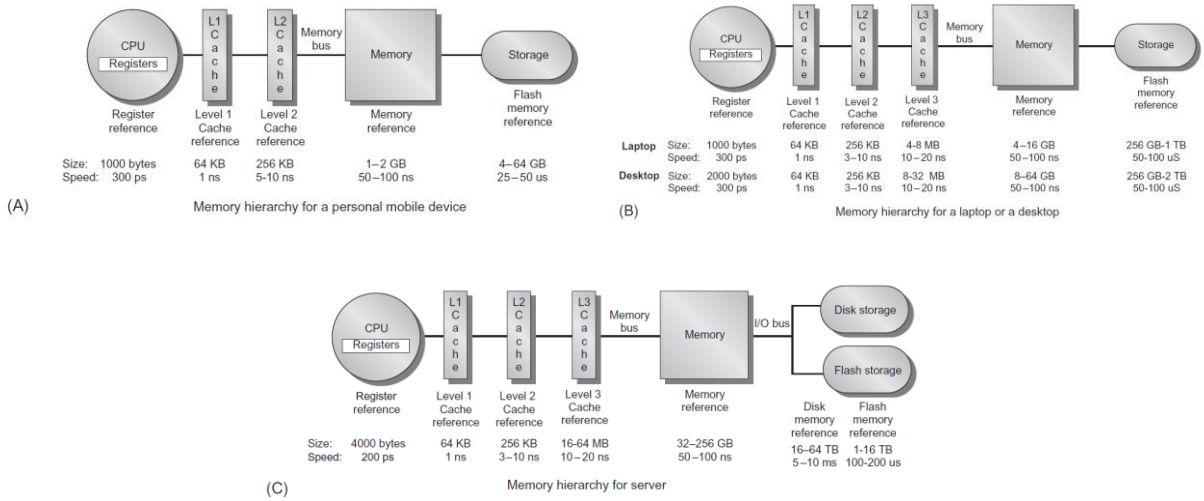
Dynamic Random Access Memory (DRAM)

- Optimized for Capacity and Low Cost, sacrificing access latency
- Χρησιμοποιείται για την κατασκευή της Κύρια Μνήμης
- 1 transistor/bit
- 20× μικρότερο μέγεθος του Cell σε σχέση με την SRAM
  - Πυκνότερη (Denser)
  - Πιο φθηνή
- Χρειάζεται να ξαναγράψουμε μια λέξη μόλις την διαβάσουμε για να μην τη χάσουμε
- Χρειάζεται Refresh περιοδικά για να κρατά τα δεδομένα για μεγάλα χρονικά διαστήματα
  - Κάθε 8ms περίπου (~5% του χρόνου)
- 2×-10× πιο αργή από την SRAM



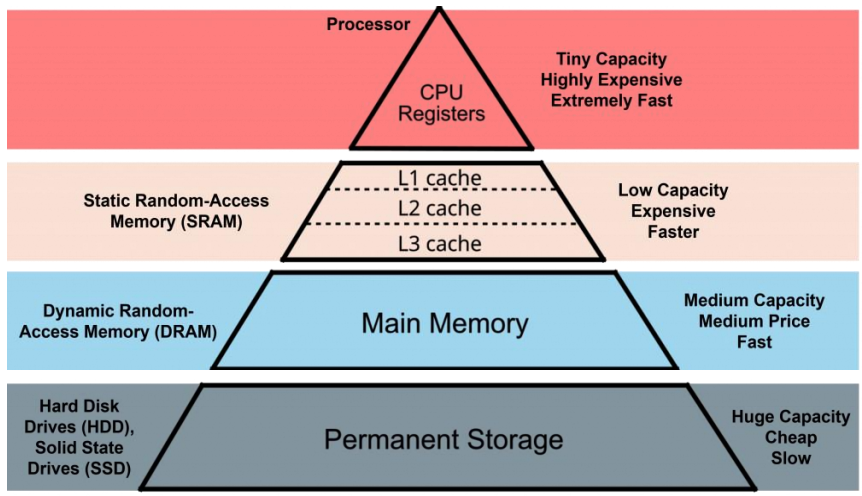
Trench capacitors take little area

Εισαγωγή – Ιεραρχία της μνήμης



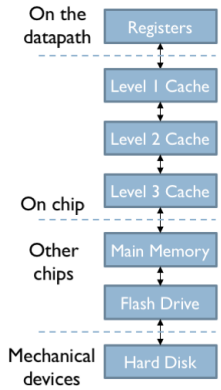
7

Εισαγωγή – Πυραμίδα της μνήμης



8

Χαρακτηριστικά

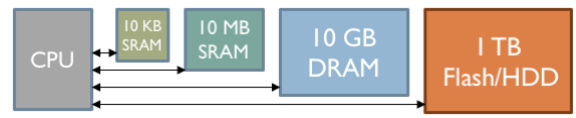


Access time	Capacity	Managed By
1 cycle	1 KB	Software/Compiler
2-4 cycles	32 KB	Hardware
10 cycles	256 KB	Hardware
40 cycles	10 MB	Hardware
200 cycles	10 GB	Software/OS
10-100us	100 GB	Software/OS
10ms	1 TB	Software/OS

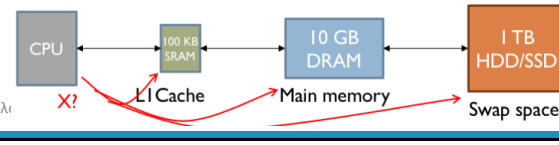
Memory Hierarchy Interface

- **1η Μέθοδος:** Εκθέτουμε την ιεραρχία μνήμης στον προγραμματιστή
  - Registers, Cache, DRAM, Hard Disk, etc.
  - Οι προγραμματιστές αποφασίζουν…





- **2η Μέθοδος:** Κρύβουμε την ιεραρχία μνήμης
  - Προγραμματιστικό Μοντέλο
    - Single Memory, Single Address Space
  - Η μηχανή αποφασίζει με διάφανο τρόπο (transparently) για το πως αποθηκεύονται τα δεδομένα σε κάθε επίπεδο



Ιεραρχία Μνήμης και Τοπικότητα

- Όσο πιο κοντά στον επεξεργαστή:
  - Πιο γρήγορη μνήμη
  - Πιο μικρή χωρητικότητα
  - Πιο ακριβή
- Όσο πιο μακριά από τον επεξεργαστή:
  - Πιο αργή μνήμη
  - Πιο μεγάλη χωρητικότητα
  - Πιο φθηνή



- **Ιεραρχία Μνήμης:** Οργανωμένη σε επίπεδα με βάση την ταχύτητα, το μέγεθος και την εγγύτητα με το CPU
- **Στόχος:** Εξισορρόπηση επίδοσης (ταχύτητας ανάγνωσης/γραφής) και κόστους

Αρχή της Τοπικότητας

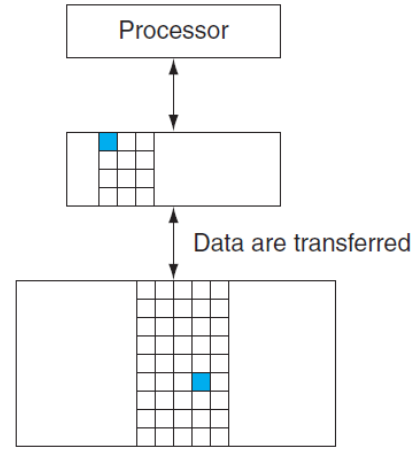
Τα προγράμματα (συνήθως) έχουν πρόσβαση σε ένα μικρό κομμάτι των δεδομένων τους ανά πάσα στιγμή

- Χρονική Τοπικότητα (Temporal Locality): Τα δεδομένα τα οποία χρησιμοποιήθηκαν πρόσφατα είναι πιθανό να χρησιμοποιηθούν ξανά σύντομα
  - Π.χ. εντολές σε ένα loop
- Χωρική Τοπικότητα (Spatial Locality): Τα δεδομένα τα οποία βρίσκονται κοντά σε άλλα δεδομένα τα οποία χρησιμοποιήθηκαν πρόσφατα είναι πιθανό να χρησιμοποιηθούν σύντομα
  - Π.χ. σειριακή πρόσβαση σε δεδομένα ενός πίνακα

Πως μπορούμε να εκμεταλλευτούμε την Τοπικότητα?

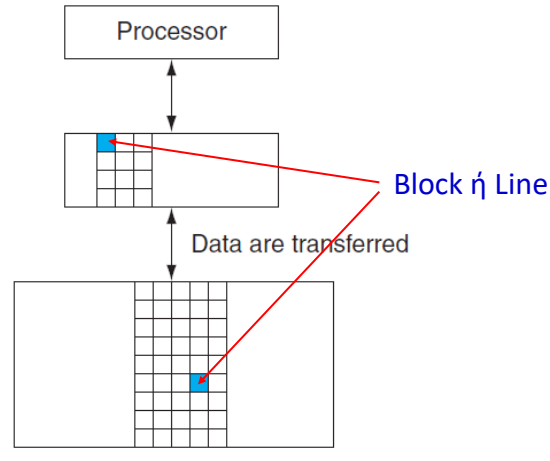
- Ιεραρχία μνήμης!

1. Αποθηκεύουμε τα πάντα στο δίσκο
2. Αντιγράφουμε από τον δίσκο τα δεδομένα που χρησιμοποιήθηκαν πρόσφατα (Temporal Locality) και τα γειτονικά τους δεδομένα (Spatial Locality) στην κύρια μνήμη
3. Αντιγράφουμε από την κύρια μνήμη τα δεδομένα που χρησιμοποιήθηκαν πρόσφατα (Temporal Locality) και τα γειτονικά τους δεδομένα (Spatial Locality) στην Cache



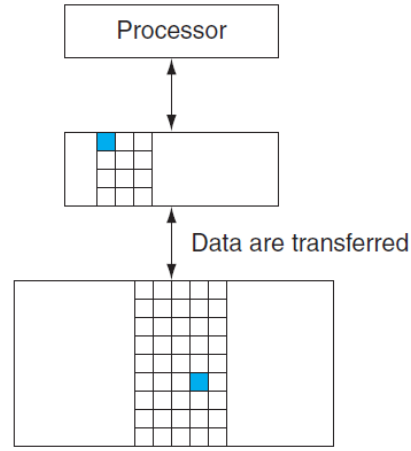
Η βασική δομή ιεραρχίας της μνήμης

- Κάθε επίπεδο περιέχει τα δεδομένα του + όλα τα δεδομένα των προηγούμενων/υψηλότερων επιπέδων (που είναι πιο κοντά στον επεξεργαστή)
- Τα δεδομένα αντιγράφονται μεταξύ γειτονικών επιπέδων
- **(Memory) Block ή Line**: Η μικρότερη μονάδα πληροφορίας που μπορεί να υπάρχει μεταξύ δύο γειτονικών επιπέδων
  - Ένα block περιέχει πολλά δεδομένα (πολλές μεταβλητές)



Ορολογία πρόσβασης στην ιεραρχία της μνήμης

- Hit: Τα δεδομένα βρίσκονται στο αμέσως επόμενο επίπεδο (cache)
- Hit Ratio: hits/access
- Miss: Τα δεδομένα δεν βρέθηκαν στη cache και πρέπει να αναζητηθούν σε χαμηλότερο επίπεδο
- Miss Ratio: misses/accesses = 1 – hit ratio
- Miss Penalty: Ο χρόνος που χρειάζεται να τα φέρει από το πιο χαμηλό επίπεδο
  - Εξαρτάται από πιο επίπεδο θα τα φέρει (Κύρια μνήμη, Δίσκο,…)



Ενότητα 07: Ιεραρχία Μνήμης Ι

ΕΕΙ 233: ΟΡΓΑΝΩΣΗ ΥΠΟΛΟΓΙΣΤΩΝ

ΑΝΔΡΕΑΣ ΔΙΑΒΑΣΤΟΣ

andreas.diavastos@cut.ac.cy