ΗΜΠ 238: Προγραμματισμός Συστημάτων

Κανονικές εκφράσεις (Regular Expressions)

- Μια κανονική έκφραση είναι ένας σύντομος και σαφής τρόπος έκφρασης οποιουδήποτε συνδυασμού χαρακτήρων.
- Οι κανονικές εκφράσεις (RE) αποτελούνται από συνδυασμό κανονικών χαρακτήρων με έναν ή περισσότερους μεταχαρακτήρες. Οι μεταχαρακτήρες είναι χαρακτήρες με ειδική σημασία που καθορίζεται από το φλοιό που τους χρησιμοποιεί (π.χ. Bourne, Korn, ή C-shell).

- Οι κανονικές εκφράσεις μπορούν να χρησιμοποιηθούν σε εντολές και προγράμματα του UNIX για:
- Να προσδιορίσουν ονόματα αρχείων
- Να ανιχνεύσουν περιεχόμενα αρχείων
- Να μεταβάλλουν περιεχόμενα αρχείων
- Κάθε εντολή του UNIX διαφέρει όσον αφορά τον τύπο των RE που υποστηρίζει. Ο προσδιορισμός των RE που υποστηρίζονται από κάθε εντολή είναι προτιμότερο να γίνεται ελέγχοντας την εντολή μέσω της εντολής man (manual pages)

Παραδείγματα

- Οι κανονικές εκφράσεις χρησιμοποιούνται κυρίως για την αναζήτηση αλφαριθμητικών γενικής μορφής σε ένα αρχείο. Π.χ.
  - Για την εύρεση όλων των γραμμών ενός αρχείου που περιέχουν ένα από τα παρακάτω:
    - Τη λέξη Unix,
    - Τη λέξη UNIX,
    - Ένα πρότυπο (pattern) που αποτελείται από 4 ψηφία
    - Έναν ταχυδρομικό κωδικό,
    - Ένα όνομα,
    - Όλα τα φωνήεντα σε αλφαβητική σειρά.

Κανονικές εκφράσεις

Προτάθηκαν για πρώτη φορά το 1956 (S. Kleene)

- Ο Ken Thomson (1968) τις χρησιμοποίησε στην εντολή grep (global regular expression print)

Μια κανονική έκφραση είναι ένα πρότυπο αποτελούμενο από μια ακολουθία χαρακτήρων που αντιστοιχούνται με το προς εξέταση κείμενο.

Το UNIX εξετάζει το κείμενο ως προς το πρότυπο για να αποφασίσει αν το πρότυπο (pattern) και το κείμενο (text) ταιριάζουν (αντιστοιχούνται).

Αν υπάρχει αντιστοιχία η έκφραση είναι αληθής και η εντολή που χρησιμοποιεί το πρότυπο εκτελείται.

Μερικές από τις πλέον ισχυρές εντολές (λειτουργίες) του UNIX, όπως grep και sed, χρησιμοποιούν κανονικές εκφράσεις.

Κανονικές εκφράσεις

- Μια κανονική έκφραση είναι μια σειρά από κανονικούς χαρακτήρες και ειδικούς τελεστές.
- Οι κανονικοί χαρακτήρες περιλαμβάνουν το σύνολο των πεζών και κεφαλαίων γραμμάτων, τα ψηφία, και άλλους συχνά χρησιμοποιούμενους χαρακτήρες : ~, ', !, @, #, _, -, =, :, ;, ,,/
- Οι ειδικοί τελεστές είναι \, ., *, [, ^, $,].

Κανονική έκφραση

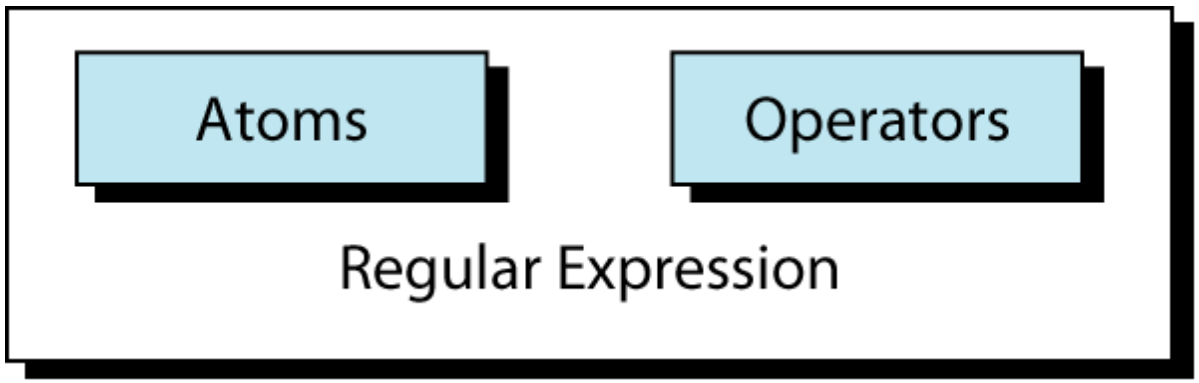
Μια κανονική έκφραση είναι παρόμοια με μια μαθηματική έκφραση.

Μια μαθηματική έκφραση αποτελείται από τελεστέους (operands) και τελεστές (operators).

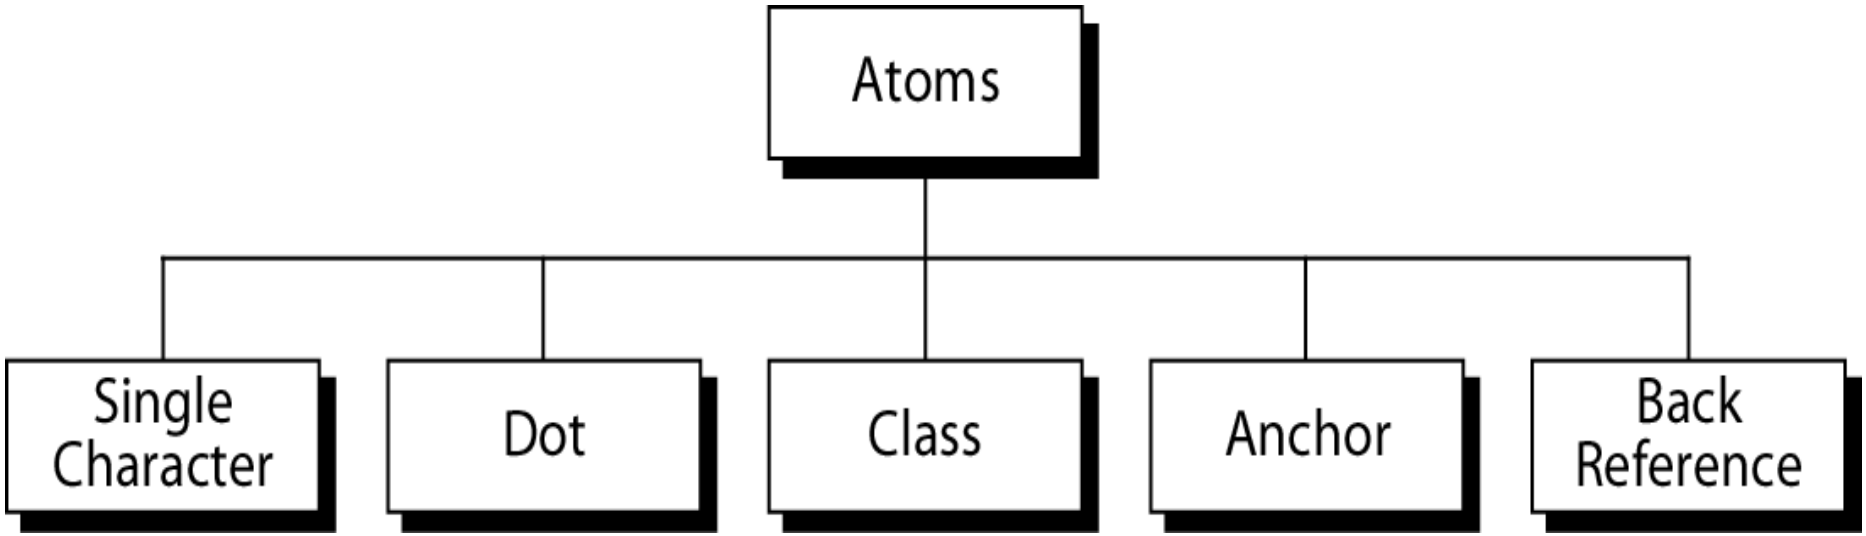
Μια κανονική έκφραση αποτελείται από atoms και operators.

Το atom προσδιορίζει αυτό που αναζητούμε και το σημείο του κειμένου όπου υπάρχει αντιστοιχία.

Ένας operator συνδυάζει atoms σε σύνθετες εκφράσεις.

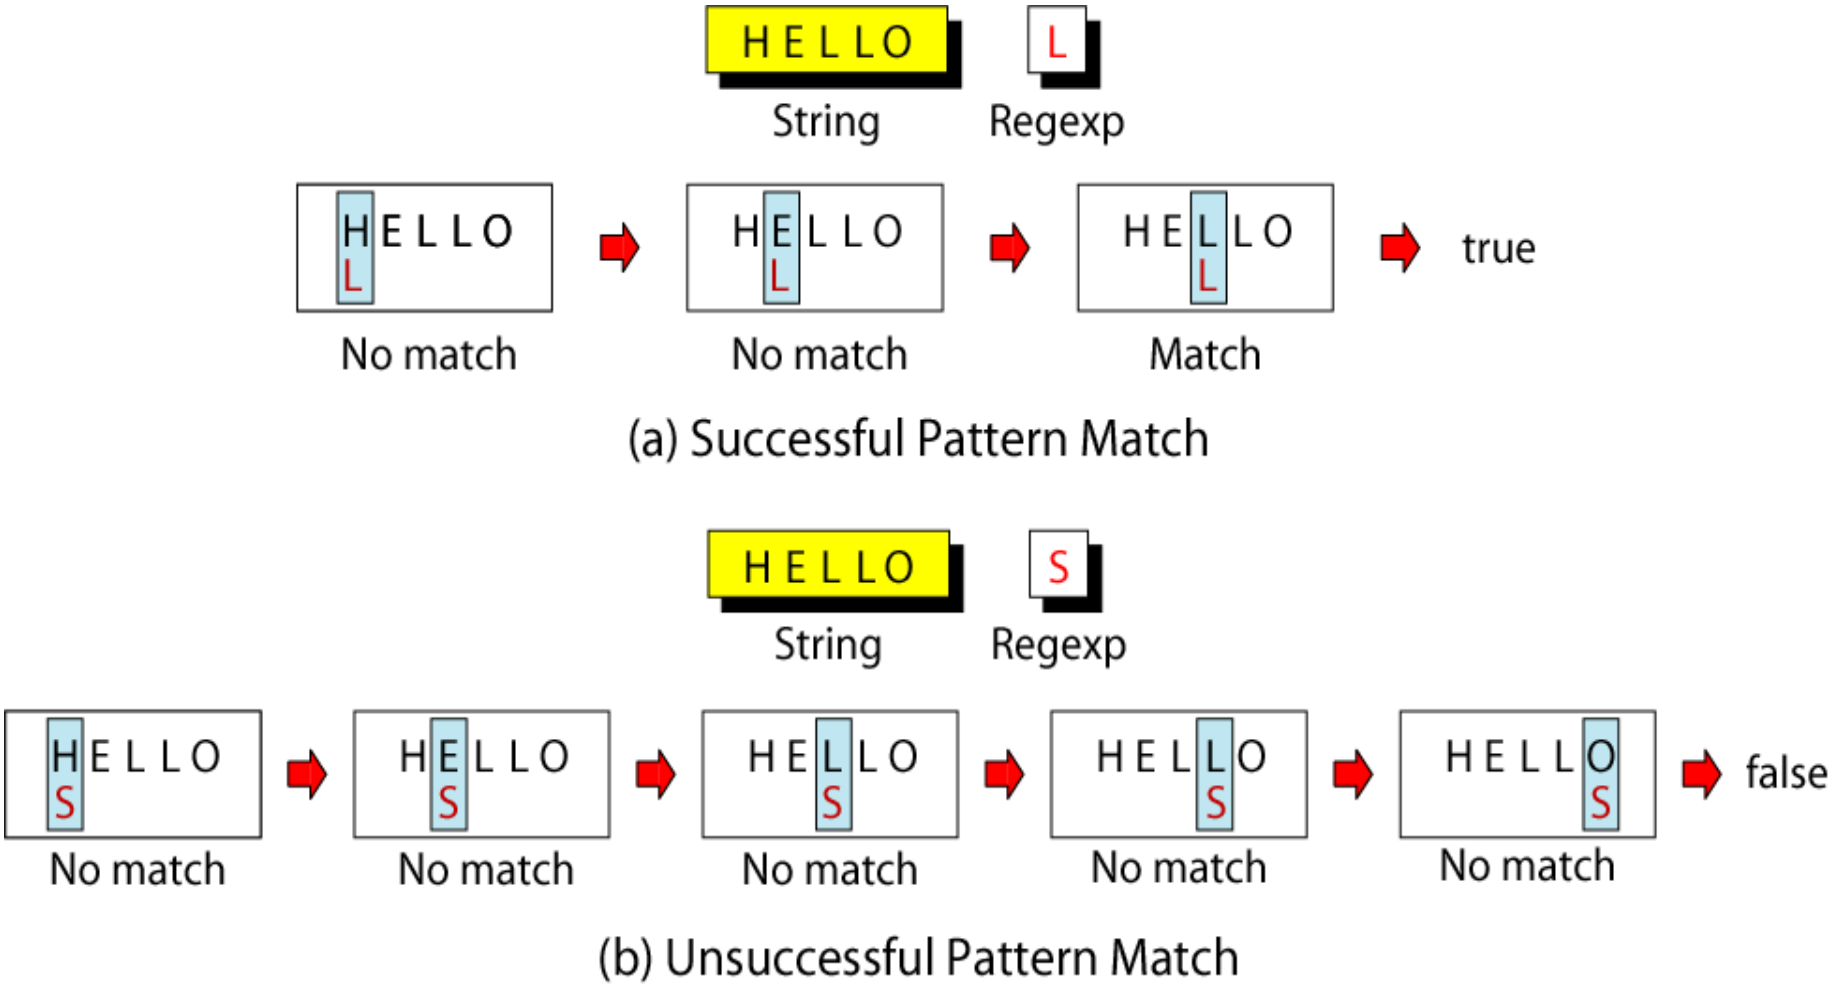


Atoms



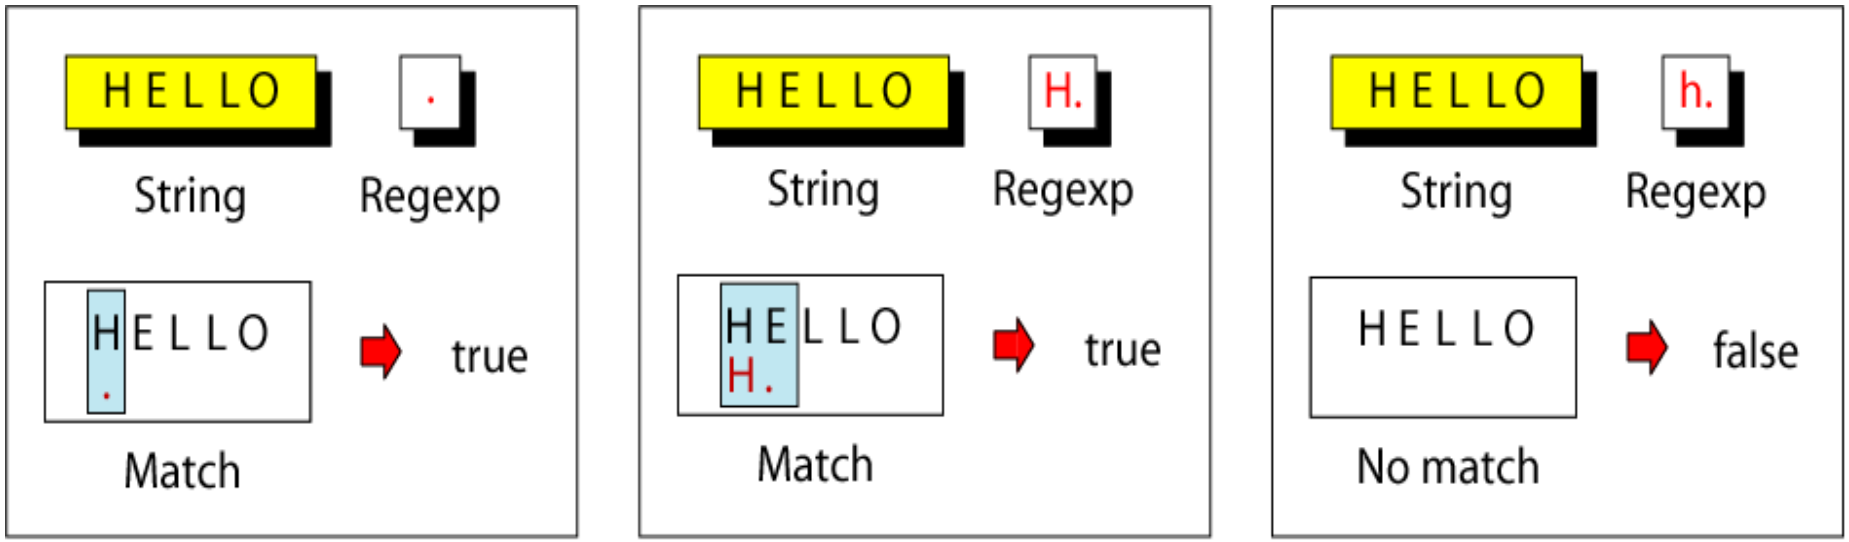
Παράδειγμα προτύπου ενός χαρακτήρα

Το απλούστερο atom είναι ένας χαρακτήρας.



Παράδειγμα Dot Atom

Μια τελεία (dot) αντιστοιχεί με οποιοδήποτε απλό χαρακτήρα εκτός από τον new line character (\n).



(a) Single-Character (b) Combination–True (c) Combination–False

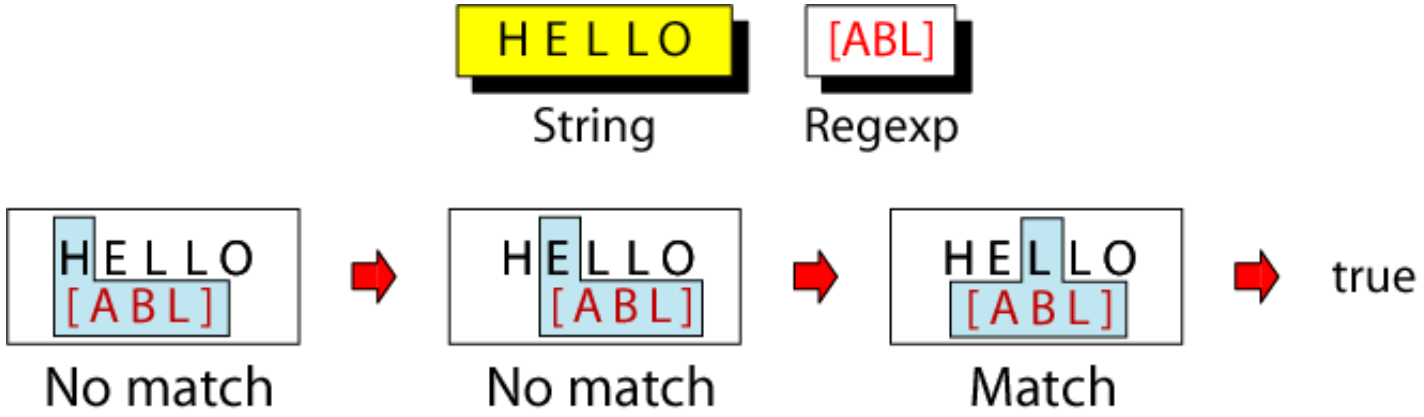
Παράδειγμα Class Atom

Μια class atom ορίζει ένα σύνολο ASCII χαρακτήρων, καθένας από τους οποίους μπορεί να αντιστοιχεί με οποιουσδήποτε χαρακτήρες του κειμένου.

Το σύνολο χαρακτήρων που χρησιμοποιείται στη διαδικασία αντιστοίχισης (matching process) περικλείεται σε αγκύλες.

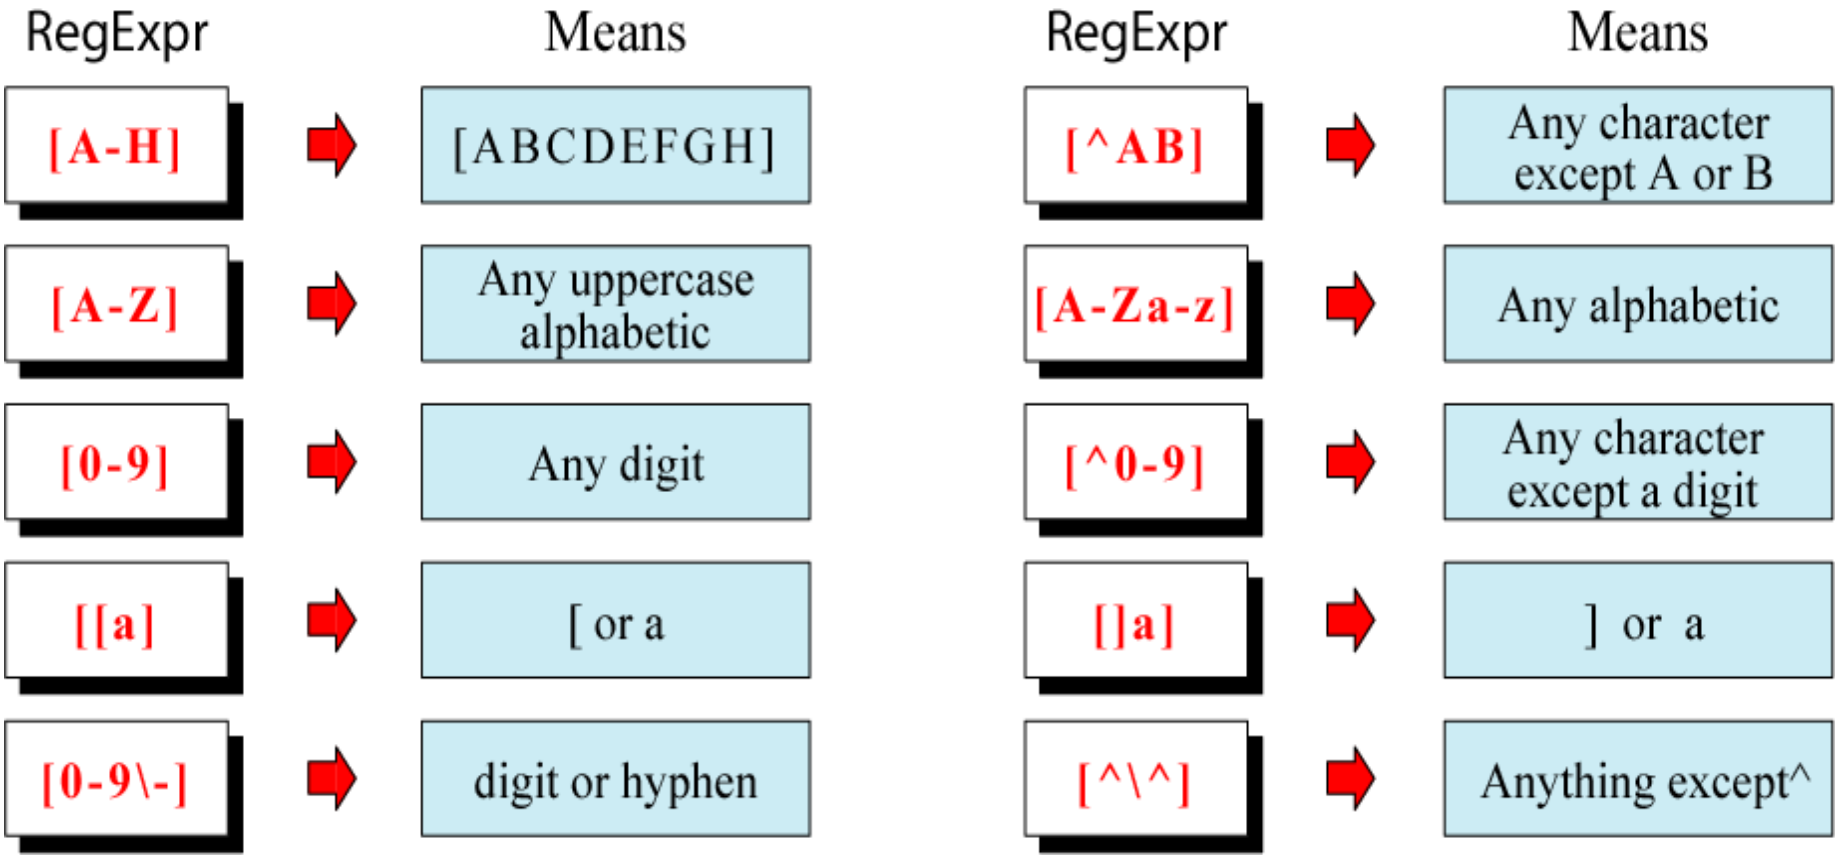
Μια περιοχή (range) χαρακτήρων κειμένου ορίζεται με μια παύλα (-) π.χ. [a-d]

Το ^ είναι ένας χαρακτήρας εξαίρεσης π.χ. [^aeiou].



Παραδείγματα κλάσεων

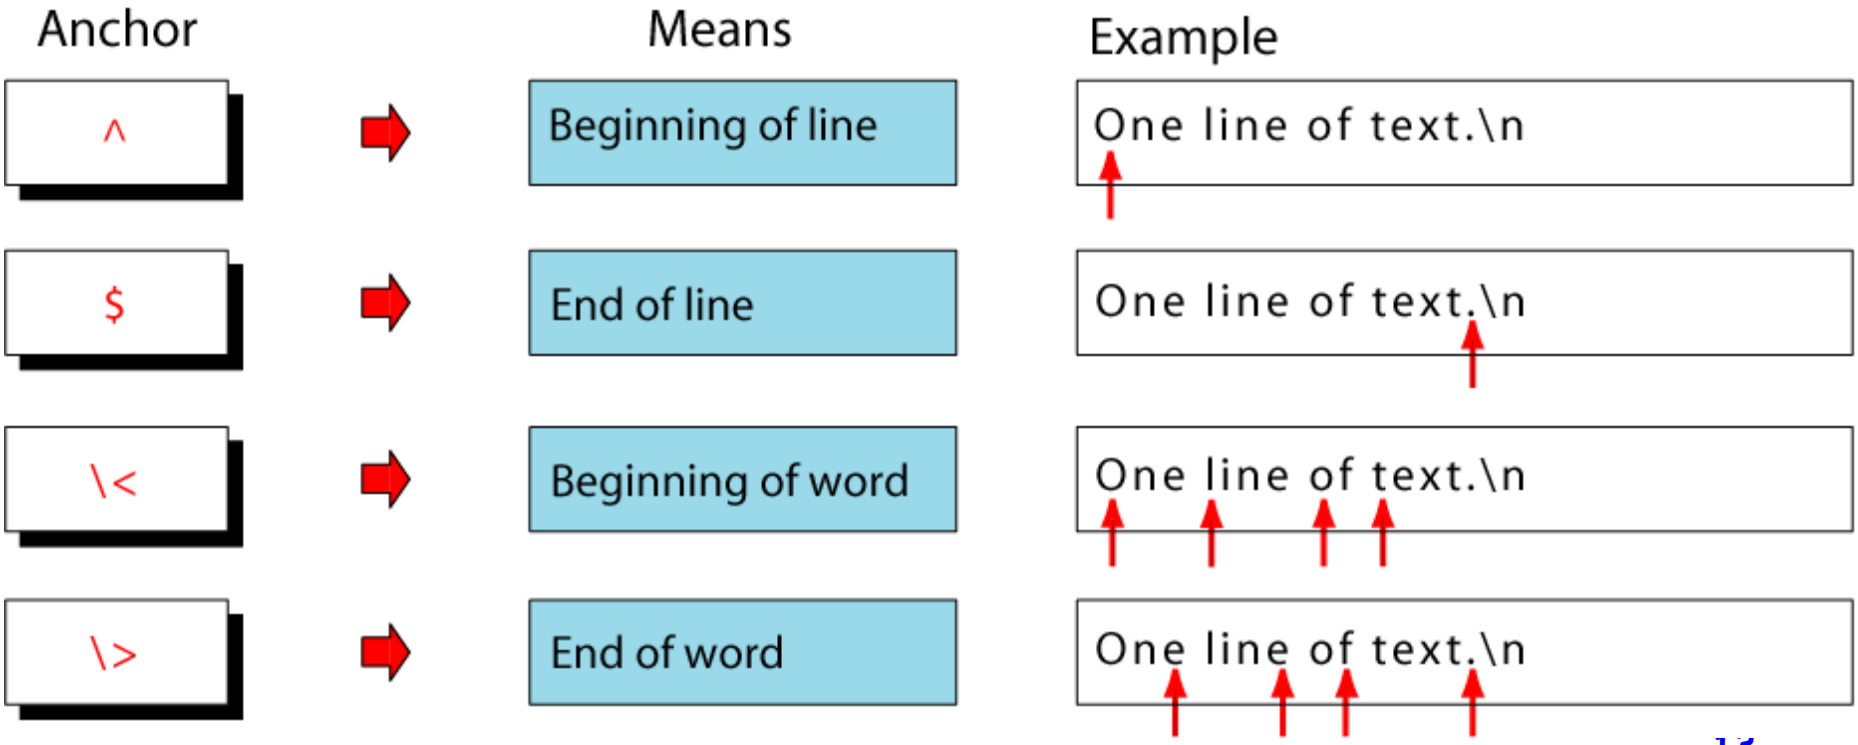
Ο escape character (\) χρησιμοποιείται όταν ο αντιστοιχούμενος χαρακτήρας είναι ένας από τους – και ^



Anchors

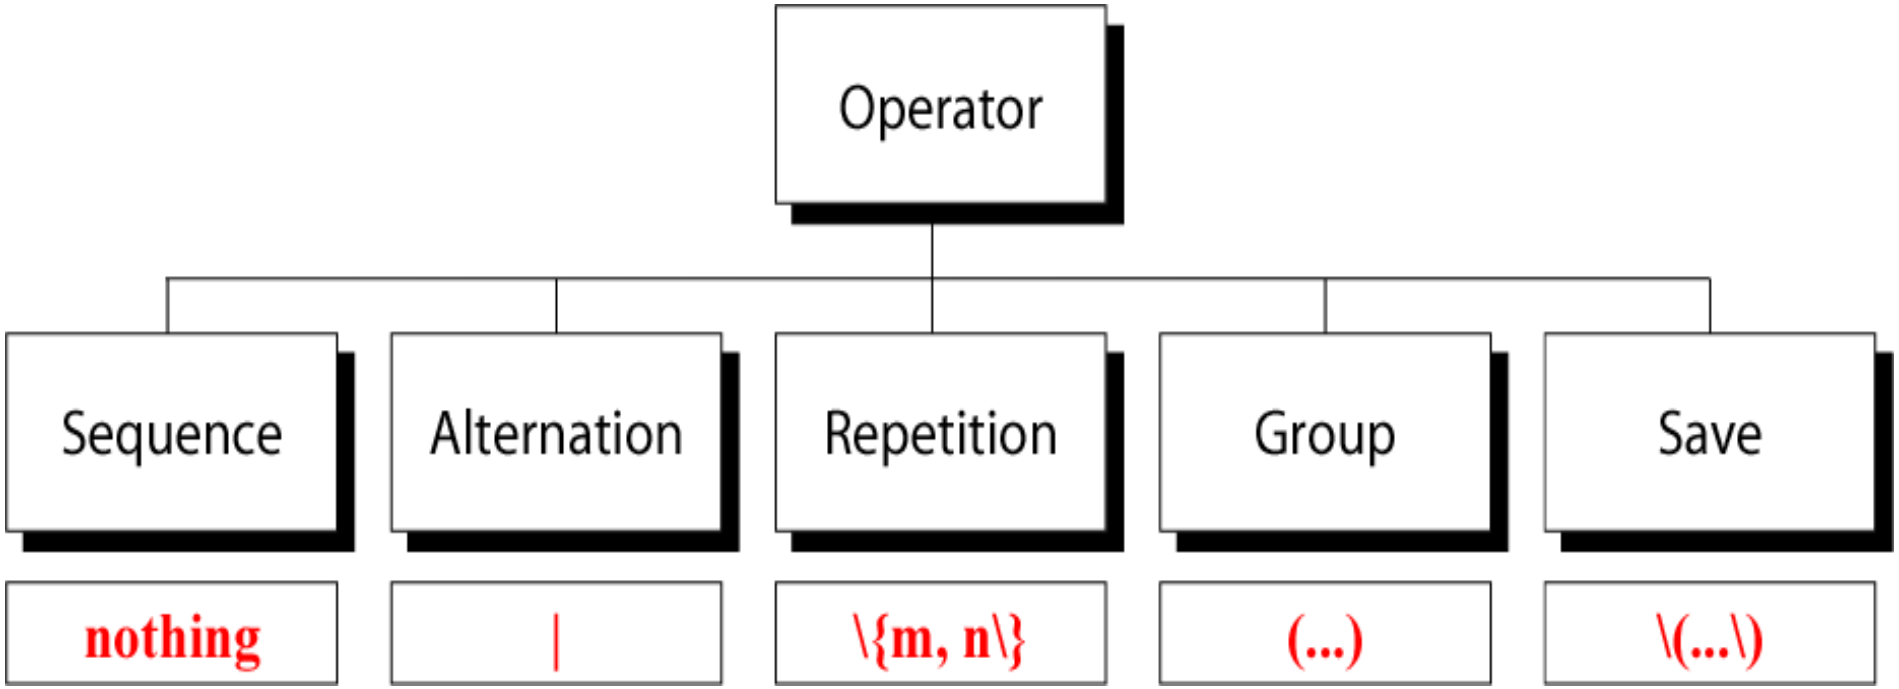
Anchors : είναι atoms που χρησιμοποιούνται για να αντιστοιχήσουν το πρότυπο σε ένα συγκεκριμένο τμήμα

Τα Anchors δεν αντιστοιχούνται στο κείμενο αλλά καθορίζουν το σημείο όπου πρέπει να βρεθεί ο επόμενος χαρακτήρας στο πρότυπο.



Operators

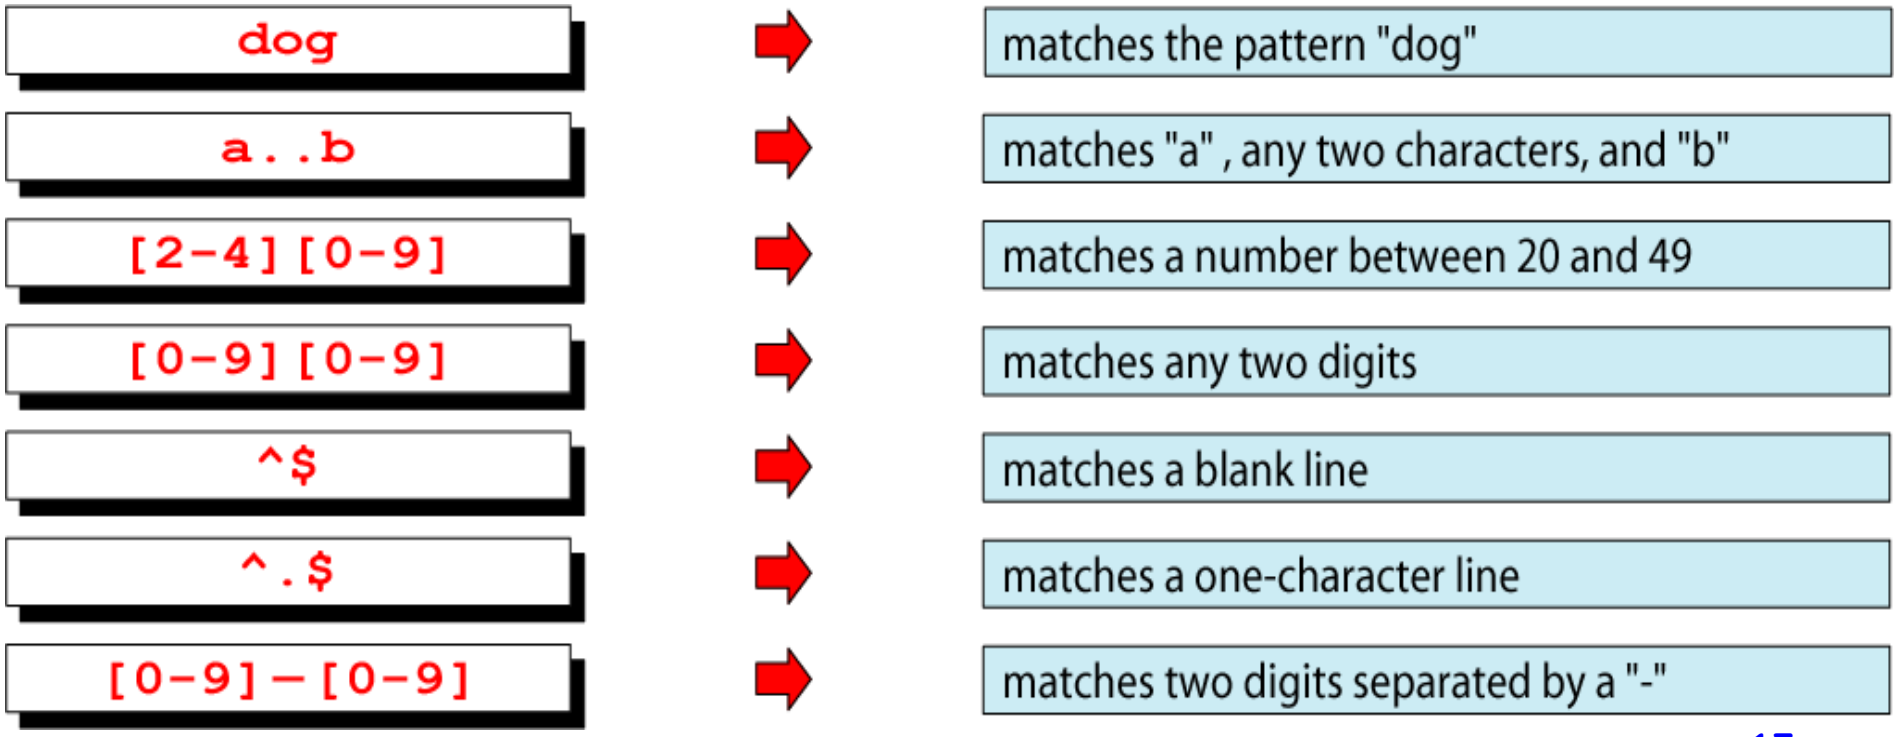
Μπορούμε να συνδυάσουμε atoms με operators.



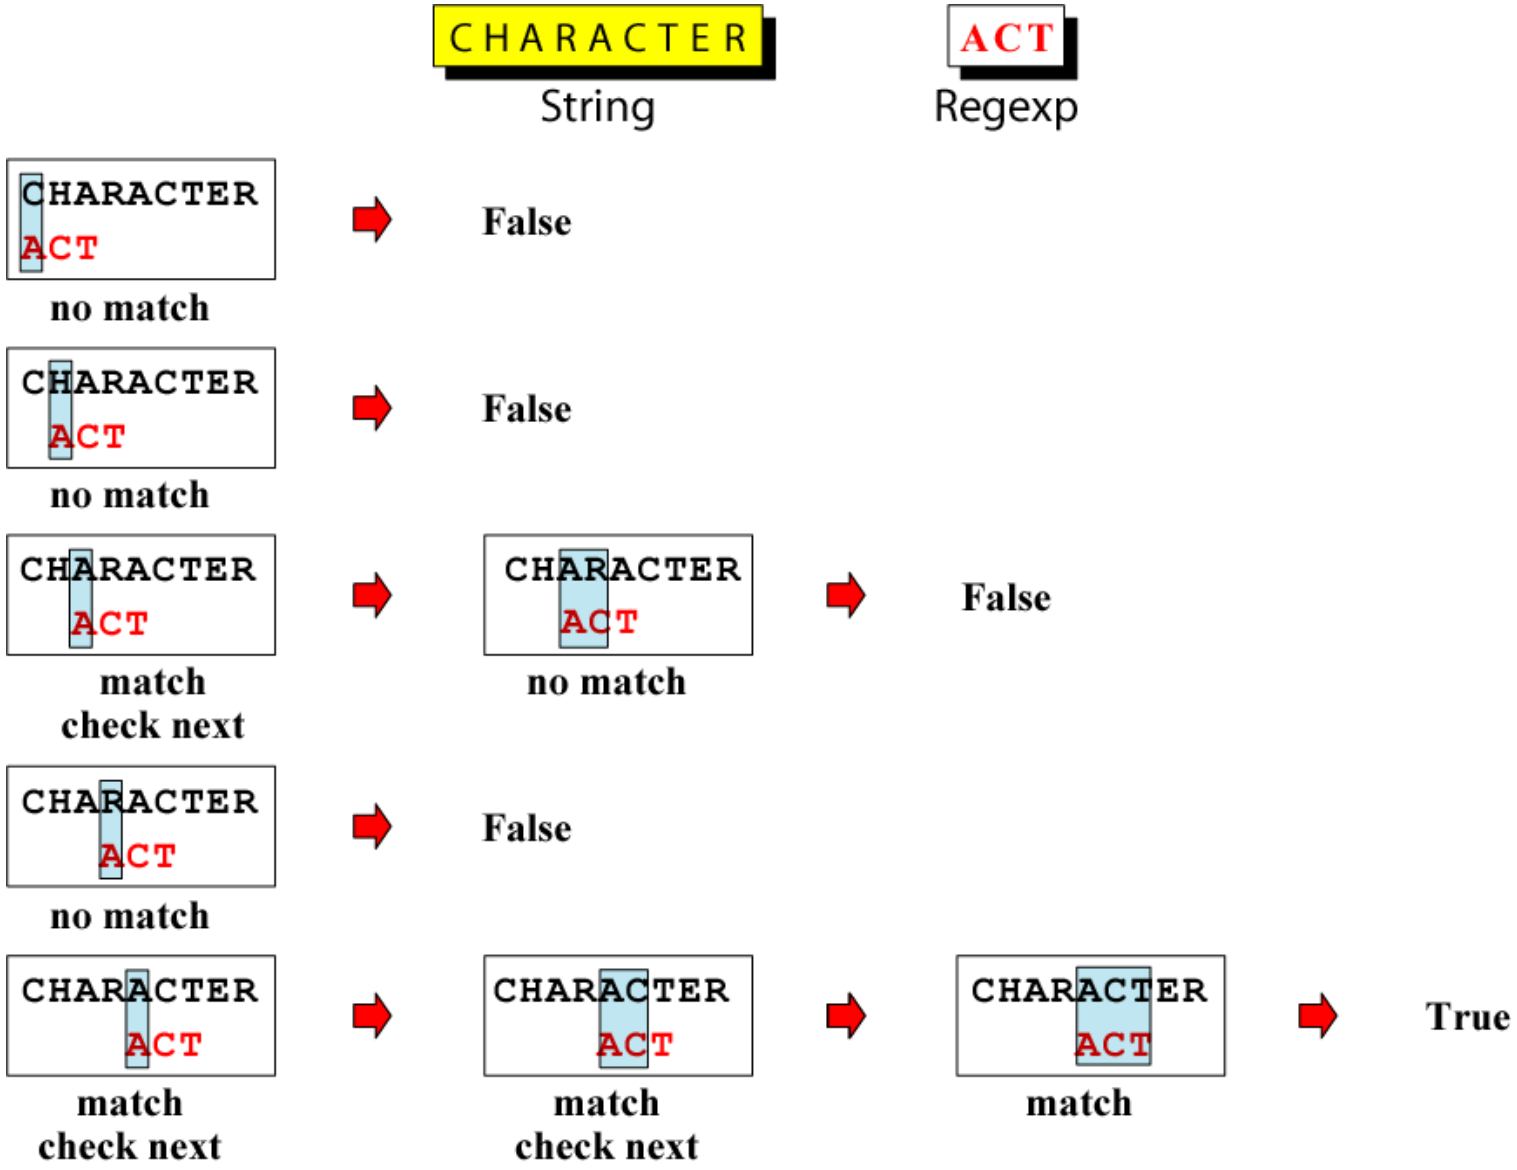
Παραδείγματα Sequence Operator

Ο τελεστής ακολουθίας (sequence operator) δεν υπάρχει.

Αυτό σημαίνει ότι αν μια σειρά από atoms φαίνονται σε μια κανονική έκφραση, υποδηλώνεται η παρουσία ενός αόρατου sequence operator ανάμεσά τους.

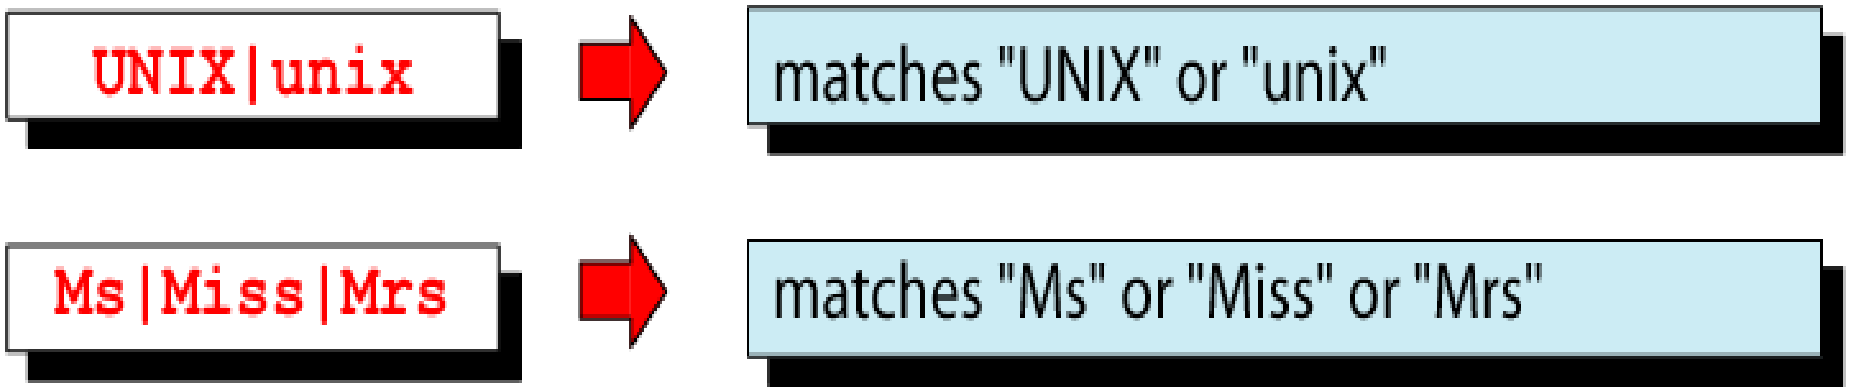


Παράδειγμα χρήσης Sequence Operator

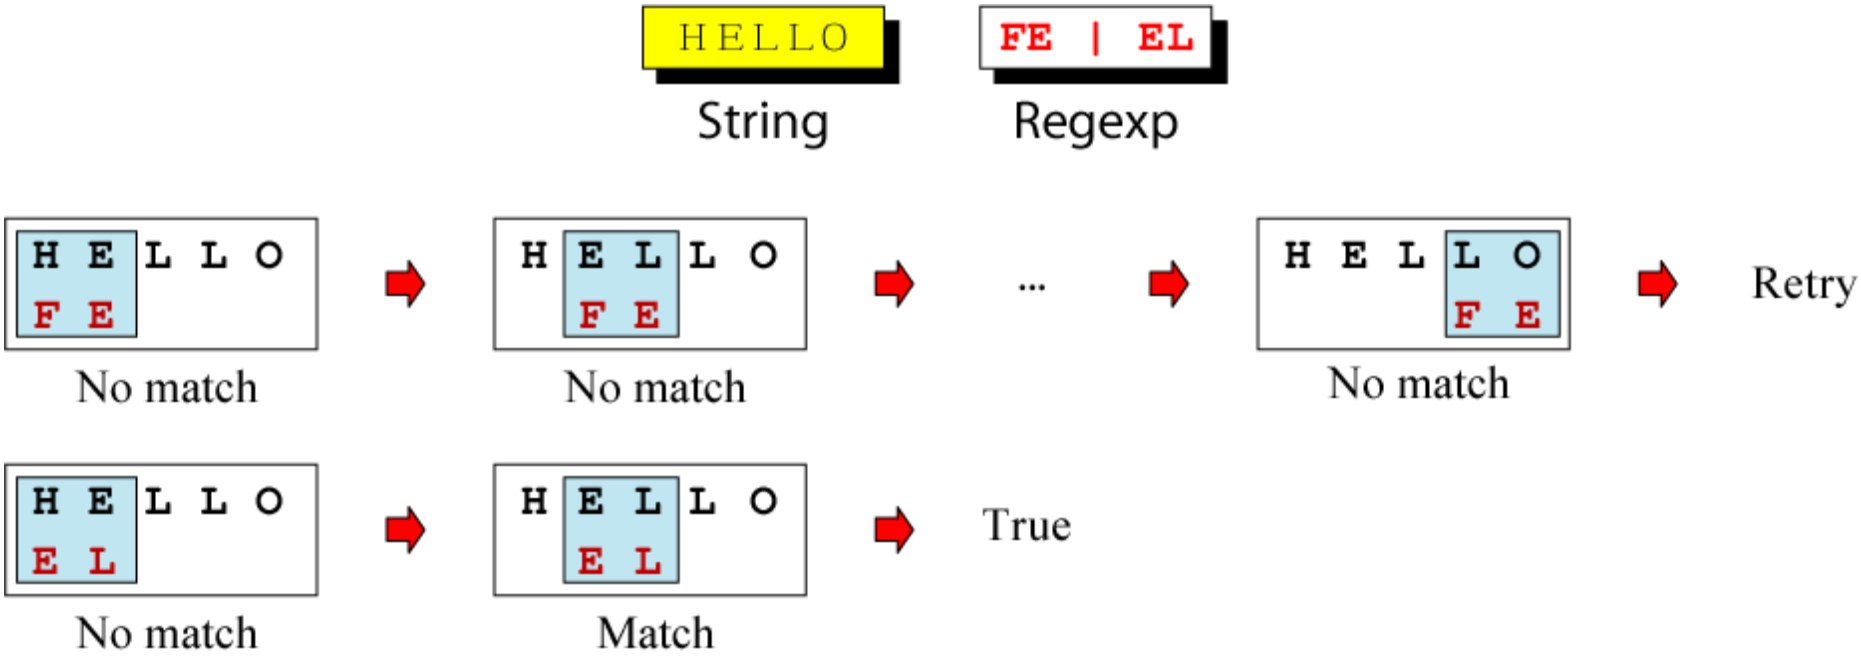


Τελεστής εναλλαγής (Alternation Operator)

Ο τελεστής εναλλαγής (alternation operator) χρησιμοποιείται για να ορίσει μια ή περισσότερες εναλλακτικές περιπτώσεις



Αντιστοίχιση Alternation Operators

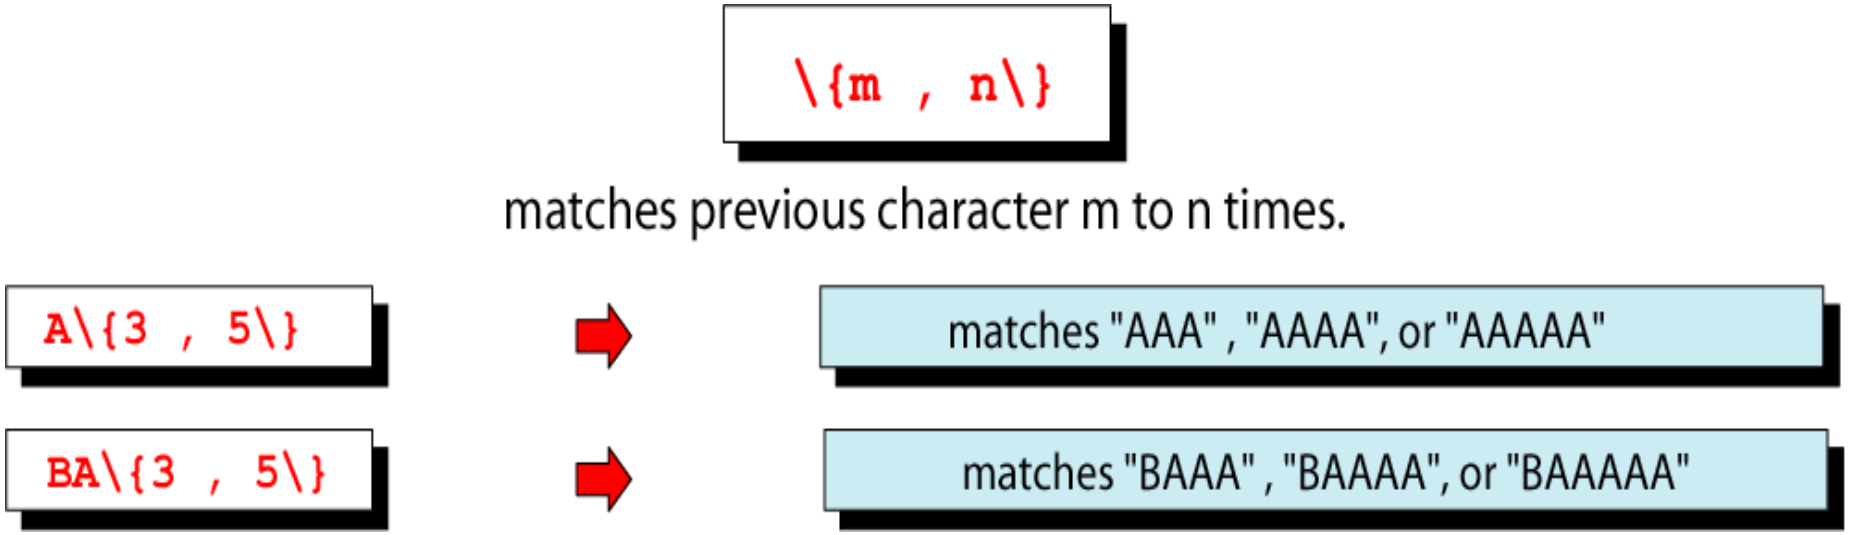


Τελεστής επανάληψης (Repetition Operator)

Ο τελεστής επανάληψης (repetition operator) καθορίζει ότι το atom ή η έκφραση που υπάρχει ακριβώς πριν από την επανάληψη μπορεί να επαναληφθεί.

m είναι ο ελάχιστος αριθμός επαναλήψεων.

n είναι ο μέγιστος αριθμός επαναλήψεων.



Βασικές φόρμες επανάληψης

Formats

`\{m\}`	➡	matches previous atom exactly m times
`\{m, \}`	➡	matches previous atom m times or more
`\{, n\}`	➡	matches previous atom n times or less

Examples

`CA\{5\}`	➡	`CAAAAA`
`CA\{3,\}`	➡	`CAAA, CAAAA, CAAAAA, …`
`CA\{,2\}`	➡	`C, CA, CAA`

Παραδείγματα με τελεστές επανάληψης

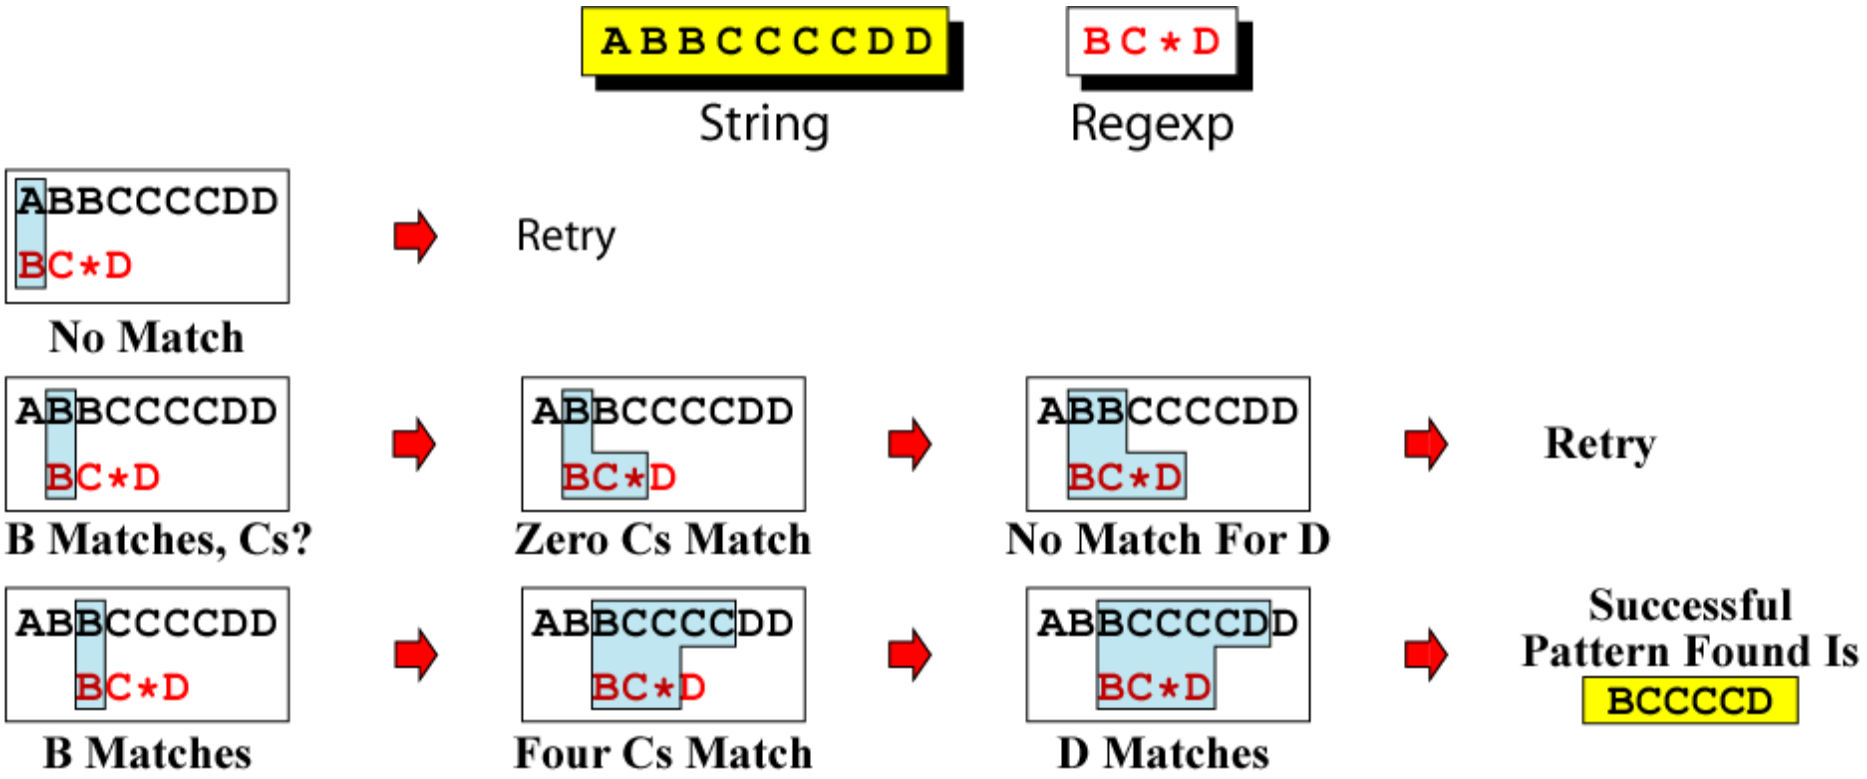
Formats

`*`	special case: matches previous atom zero or more times
`+`	special case: matches previous atom one or more times
`?`	special case: matches previous atom 0 or one time only

Examples

`BA*`	B, BA, BAA, BAAA, BAAAA, . . .
`B.*`	B, BA . . . BZ, BAA . . . BZZ, BAAA . . . BZZZ, . . .
`.*`	zero or more characters
`.+`	one or more characters
`[0-9]?`	zero or one digit

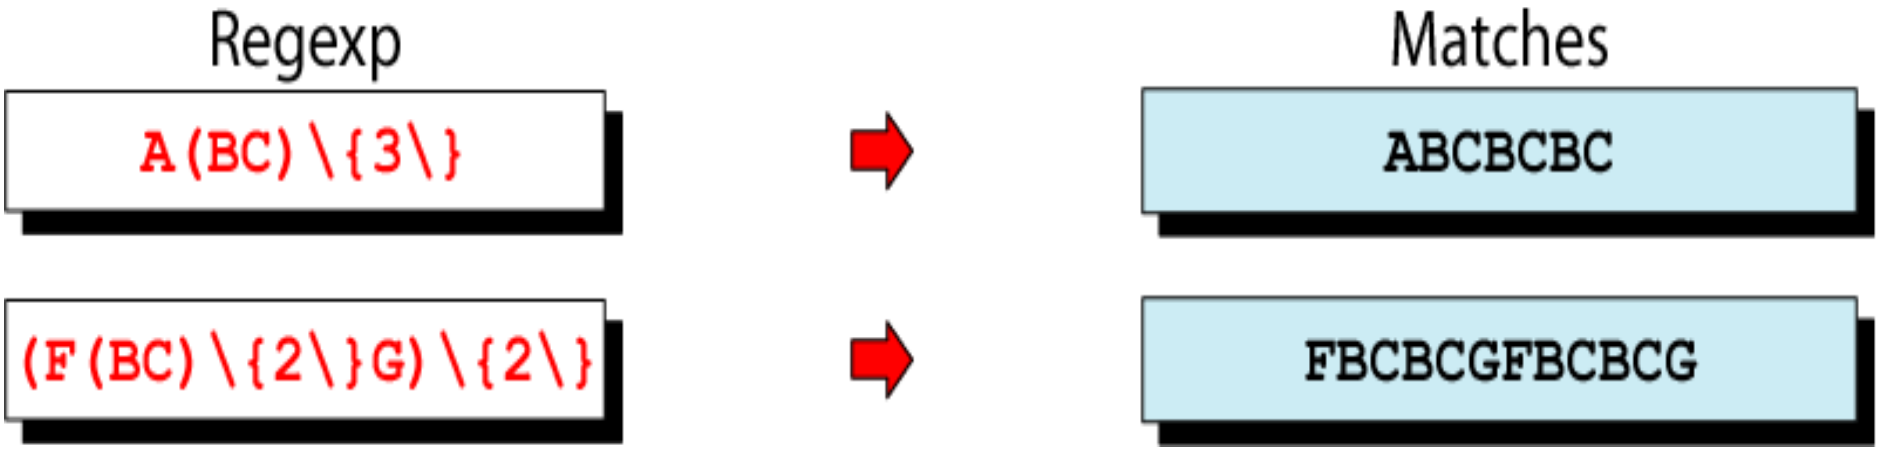
Επαναλαμβανόμενη αντιστοίχιση προτύπων



Τελεστής ομαδοποίησης (Group Operator)

Ο group operator είναι ένα ζεύγος παρενθέσεων που ανοίγουν και κλείνουν.

Όταν μια ομάδα χαρακτήρων περικλείεται σε παρενθέσεις ο επόμενος τελεστής εφαρμόζεται σε όλη την ομάδα.



Η οικογένεια grep

- Οι εντολές grep, egrep, fgrep χρησιμοποιούνται για την αντιστοίχιση ενός προτύπου χαρακτήρων
- Για την ομαλή λειτουργία οι κανονικές εκφράσεις πρέπει να περικλείονται σε οριοθέτες (π.χ. ‘ ‘) ώστε ο φλοιός να διερμηνεύσει τους χαρακτήρες που περιέχονται στην κανονική έκφραση ως “grep special characters” και όχι ως “shell special characters”

Η εντολή grep (general regular expression print)

επιλογή	σημασία
-c	Εμφανίζει το πλήθος των γραμμών που ταιριάζουν με το πρότυπο
-i	Αγνοεί τη διάκριση μεταξύ πεζών και κεφαλαίων γραμμάτων
-l	Εμφανίζει τα ονόματα των αρχείων που ταιριάζουν με το πρότυπο
-n	Περιλαμβάνει τους αριθμούς γραμμών
-v	Εμφανίζει τις γραμμές που δεν αντιστοιχούν στο πρότυπο

- Μορφές κανονικών εκφράσεων :
  - Απλό κείμενο
    - grep unix file (αναζητεί όλες τις εμφανίσεις της λέξης unix στο αρχείο file και εμφανίζει τις γραμμές που περιέχονται)
  - Κείμενο που περιέχει ειδικούς χαρακτήρες
    - grep '[uU]nix' file (αναζητεί unix και Unix)

Παραδείγματα

$ grep studin /etc/passwd

Αναζητούνται και εμφανίζονται όλες οι γραμμές του αρχείου passwd που περιέχουν το πρότυπο studin.

$ grep "^studin" /etc/passwd

Αναζητούνται και εμφανίζονται όλες οι γραμμές του αρχείου passwd που ξεκινούν με το πρότυπο studin

Άσκηση

- Να προσδιοριστεί ένα πρότυπο που θα εμφανίζει όλες τις γραμμές του αρχείου passwd που ξεκινούν με τη λέξη studin και στη συνέχεια δεν θα ακολουθεί πεζός χαρακτήρας.

  $ grep "^studin[^a-z]" /etc/passwd

  $ grep '^studin[a-z]' /etc/passwd

  Εμφανίζει τις γραμμές που εξαιρέθηκαν από το προηγούμενο πρότυπο

Wildcards & Κανονικές Εκφράσεις

- Οι χαρακτήρες – μπαλαντέρ (wildcards) είναι ένα εργαλείο που επιτρέπει την αναφορά σε ονόματα αρχείων με συγκεκριμένα χαρακτηριστικά.
- Οι κανονικές εκφράσεις ή παραστάσεις (regular expressions - RE) είναι διαφορετικά και πιο ισχυρά εργαλεία ταιριάσματος προτύπων (pattern-matching). Οι RE διερμηνεύονται και χρησιμοποιούνται από ειδικές λειτουργίες (π.χ. grep, sed).
- **Οι χαρακτήρες – μπαλαντέρ στα ονόματα αρχείων διερμηνεύονται από τον φλοιό και έχουν μεγαλύτερη προτεραιότητα, ενώ οι κανονικές εκφράσεις από τις εντολές που τις χρησιμοποιούν.**

Κανόνες δημιουργίας & αντιστοίχισης κανονικών εκφράσεων

- Οι χαρακτήρες : **.** ,*****, **[** ,**** είναι ειδικοί χαρακτήρες εκτός όταν εμφανίζονται ανάμεσα σε [ ]
- Ο χαρακτήρας **^** είναι ειδικός χαρακτήρας όταν είναι ο πρώτος που εμφανίζεται σε μια κανονική έκφραση και όταν είναι ο πρώτος χαρακτήρας μέσα σε [ ]
- Ο χαρακτήρας **$** είναι ειδικός χαρακτήρας όταν είναι τελευταίος
- Ένας ειδικός χαρακτήρας που έχει μπροστά **** είναι ο ίδιος ο χαρακτήρας (escape chars)

Πίνακας συμβολισμού κανονικών εκφράσεων

Συμβολισμός	Σημασία
c	Αντιστοιχεί στον χαρακτήρα c
\c	Αναγκάζει το c να διαβαστεί μόνον ως το γράμμα c
^	Ταυτοποιείται κατά την αναζήτηση με την αρχή της γραμμής
$	Ταυτοποιείται κατά την αναζήτηση με το τέλος της γραμμής
.	Ταυτοποιείται με ένα και μόνο χαρακτήρα
[xy]	Κάθε μεμονωμένος χαρακτήρας που περιέχεται στο σύνολο
[^xy]	Κάθε μεμονωμένος χαρακτήρας που δεν περιέχεται στο σύνολο (exclusion set)

Συμβολισμός	Σημασία
c*	καμία ή περισσότερες εμφανίσεις του χαρακτήρα c
*****	0 ή περισσότερες εμφανίσεις της έκφρασης που προηγείται
+	1 ή περισσότερες εμφανίσεις της έκφρασης που προηγείται
?	0 ή 1 εμφανίσεις της έκφρασης που προηγείται

Παραδείγματα

- Όλες οι γραμμές που δεν ξεκινούν από κεφαλαίο αγγλικό χαρακτήρα :
  - **grep '^[^A-Z]' file**
- Όλες οι γραμμές που περιέχουν !,& ,* :
  - **grep '[\!*\&]‘ file**
- Όλες οι γραμμές που περιέχουν την τιμή $1.99 :
  - **grep '\$1\.99‘ file**
- Όλες οι γραμμές με μήκος 2 χαρακτήρες :
  - **grep '^..$‘file ή ^.\{2\}$**

- Όλες οι γραμμές που έχουν μήκος ακριβώς 17 χαρακτήρες:
  - **grep '^.\{17\}$‘ file**
- Όλες οι γραμμές που έχουν μήκος τουλάχιστον 25 χαρακτήρες:
  - **grep '^.\{25,\}$'**
- Όλες οι γραμμές που δεν έχουν μήκος 3 χαρακτήρες:
  - **grep –v '^...$‘file**

- Όλες οι γραμμές που ξεκινούν με * :
  - **^***
- Όλες οι γραμμές που δεν περιέχουν αριθμούς :
  - **^[^0–9]*$**
- Όλες οι γραμμές που περιέχουν τα έτη 1991 έως 1995 :
  - **199[1-5]**
- Οποιαδήποτε ακολουθία χαρακτήρων δεν περιέχει ψηφία:
  - **[A-Za-z][A-Za-z]***

- Οποιοσδήποτε προσημασμένος ακέραιος :
  - **[+\-][0-9][0-9]***
- Οποιαδήποτε ακολουθία χαρακτήρων :
  - **.* (ιδιωματισμός!)**
- Οποιοδήποτε αναγνωριστικό (identifier) :
  - **[a-zA-Z_][a-zA-Z_0-9]***
- Οποιοσδήποτε πραγματικός αριθμός χωρίς πρόσημο:
  - **[0-9]+[.][0-9]+**
  - **[0-9]*[.][0-9]***

- Οποιοδήποτε πλήθος από * ακολουθούμενο από οποιοδήποτε πλήθος \ :
  - **‘***’**

- Ώρα σε 12ωρη βάση:
  - **‘1*[012]*[1-9]*:[0-5][0-9]’**
- **$ grep ‘:$’ /etc/passwd**

  (οι γραμμές στις οποίες δεν περιέχεται login shell)
- **$ grep ‘$100*’ ***

  (αναζητεί όλα τα αρχεία στα οποία υπάρχει το ποσό $100)

$ grep ‘z*’ /etc/passwd

(οι γραμμές με 0 ή περισσότερα z)

$ grep ‘zz*’ /etc/passwd

(οι γραμμές με 1 ή περισσότερα z)

- Να εξηγήσετε την εντολή :
  - ls -l | grep '^d.....x'

  - Εμφανίζει όλα τα directories του current directory στα οποία οι υπόλοιποι χρήστες (other) έχουν δικαίωμα eXecute

Υποθέτουμε ότι στο αρχείο passwd οι ημερομηνίες είναι στη μορφή : Feb 9, 1999 . Ποια είναι η μορφή της κανονικής έκφρασης;

‘[A-Z][a-z]* [0-9]\{1,2\}, [0-9]\{4\}’

‘[A-Z][a-z]\{3,\} [0-9]\{1,\}, [0-9]\{4\}’

- Ποια είναι η μορφή της κανονικής έκφρασης για τηλεφωνικούς αριθμούς της περιοχής Θεσσαλονίκης; (πρόθεμα : 2310, 2391,2392, …, 2396 και αριθμός εξαψήφιος στη μορφή :
  23XX-XXX-XXX)

  – **‘23[19][0-6]-[0-9]\{3\}-[0-9]\{3\}’**

Επεκτεταμένες RE : Η εντολή egrep

- Είναι υπερσύνολο της grep. Αναζητεί και αντιστοιχεί όλες τις περιπτώσεις κανονικών εκφράσεων της grep και επιπλέον :
  - Μια RE που ακολουθείται από το **+** αντιστοιχεί μία ή περισσότερες ταυτίσεις της RE
  - Μια RE που ακολουθείται από το **?** αντιστοιχεί καμία ή μία ταυτίσεις της RE
  - Πολλαπλές RE διαχωριζόμενες με **|** αντιστοιχούνται με οποιαδήποτε από τις RE που περιέχονται.
  - Μια RE μπορεί να περικλείεται σε παρενθέσεις για ομαδοποίηση

- Παραδείγματα :
  - $egrep ’19|23’ file
  - $egrep ‘[A-Z][A-Z]+’ file
  - $egrep ‘239(4|6)-(0|1) phones
  - $egrep ‘(Sally|Fred) (Smith|Jones|Parker) phones.list

Παραδείγματα με την egrep

όλες οι γραμμές που ξεκινούν με
egrep '(^#)' /etc/rc

όλες οι γραμμές που ΔΕΝ ξεκινούν με
egrep '(^[^#])' /etc/rc

όλες οι γραμμές που ξεκινούν με e, f ή g.
egrep '(^[efg])' /etc/rc

όλες οι γραμμές που ξεκινούν με κεφαλαίο γράμμα
egrep '(^[A-Z])' /etc/rc

όλες οι γραμμές που ΔΕΝ ξεκινούν με κεφαλαίο γράμμα

```
$egrep '(^[^A-Z])'      /etc/rc
```

όλες οι γραμμές που περιέχουν ! * &

```
$egrep '([\!\*\&])'     /etc/rc
```

όλες οι γραμμές που περιέχουν ! * & αλλά δεν ξεκινούν με

```
$egrep '([^#][\!\*\&])' /etc/rc
```

Η εντολή fgrep (file-based grep/fast grep)

- Χρησιμοποιείται για την ταυτόχρονη αναζήτηση πολλαπλών προτύπων και δεν χρησιμοποιεί μετα-χαρακτήρες.
- ένα αρχείο προτύπων περιλαμβάνει οποιοδήποτε πρότυπο θα αντιλαμβάνεται η grep και προσδιορίζεται από την επιλογή –f.
  - $fgrep –f pattern_file file
    - Το pattern_file περιέχει τα πρότυπα

Αποθήκευση (save)

- Ο τελεστής αποθήκευσης \(\) αντιγράφει το αλφαριθμητικό που περικλείεται σε μια προσωρινή μνήμη (buffer ή register) για μεταγενέστερη χρήση. Υπάρχουν συνολικά εννέα (9) buffers που αριθμούνται από \1 έως \9
  - \1 : είναι το τμήμα κειμένου που αντιστοιχεί στην πρώτη κανονική έκφραση σε παρένθεση
  - \2 : είναι το τμήμα κειμένου που αντιστοιχεί στην δεύτερη κανονική έκφραση σε παρένθεση
  - …..

παραδείγματα

- '^\([a-z]\)\1'
  - Αναζητεί και εμφανίζει τις γραμμές που ξεκινούν από ένα ζεύγος όμοιων γραμμάτων.
- '\([a-z][a-z]*\)\1\1'
  - Αναζητεί και εμφανίζει τις γραμμές που περιέχουν τουλάχιστον τρία αντίγραφα ενός συνόλου χαρακτήρων που αποτελείται από πεζά γράμματα.

Bill\(.\)Gates\1

αναζητεί ένα πρότυπο αλφαριθμητικού που ξεκινά με τη λέξη **Bill**, ακολουθούμενη από ένα χαρακτήρα (πλην του χαρακτήρα αλλαγής γραμμής), ακολουθούμενο από τη λέξη **Gates**, ακολουθούμενη από τον ίδιο ένα χαρακτήρα.

- Η παρακάτω ακολουθία αντιστοιχεί στο πρότυπο:

  Bill!Gates! **Bill-Gates-**

  αλλά όχι η ακολουθία:

  Bill?Gates! **Bill-Gates**

“a\(.\)b\(.\)c\2d\1”

- Το παράδειγμα αφορά ένα πρότυπο που ξεκινά με **a**, ένα χαρακτήρα (#1), ακολουθούμενο από το **b**, ακολουθούμενο από έναν άλλο χαρακτήρα (#2), **c**, το χαρακτήρα #2, **d**, και το χαρακτήρα #1.
- Η παρακάτω ακολουθία αντιστοιχεί στο πρότυπο:

  a-b!c!d-